

UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA

Unidad II: Modelos de Demanda

Partición Modal III

Prof. Cristóbal Pineda A. -  @cristpineda

CIV-386 Ingeniería de Transporte

Modelo Logit Multinomial (MNL)

$$P(i|A_q) = \frac{e^{\mu V_{iq}}}{\sum_{j \in A_q} e^{\mu V_{jq}}}$$

$$= \frac{1}{\sum_{j \in A_q} e^{\mu (V_{jq} - V_{iq})}}$$

- Depende de los atributos del modo en análisis y del resto
- Solo importan las diferencias entre alternativas

$$\mu = \frac{\pi}{\sqrt{6}\sigma}$$

- Factor de escala: no es posible estimarlo a priori (parámetro no identificable)

Modelo Logit Multinomial (MNL)

$$\mu = \frac{\pi}{\sqrt{6}\sigma}$$

- Factor de escala: no es posible estimarlo a priori (parámetro no identificable)

- Desarrollemos el término de la probabilidad que está asociado a las utilidades:

Podemos estimar este parámetro

$$P(i|A_q) = \frac{e^{\mu V_{iq}}}{\sum_{j \in A_q} e^{\mu V_{jq}}} \Rightarrow \mu V_{iq} = \mu \sum_k \theta_{ki} X_{kiq} = \sum_k \mu\theta_{ki} X_{kiq}$$

$$= \sum_k \theta'_{ki} X_{kiq} = V'_{iq}$$

- ¿Cómo estimar este nuevo parámetro θ'_{ki} ?

Modelo Logit Multinomial (MNL)

- ¿Cómo estimar estos parámetros?
  - Observamos el conjunto de atributos (X) y las elecciones (i) para cada individuo (q) θ_{ki}
  - Buscamos los parámetros tal que, al menos, las predicciones sean buenas para la muestra de calibración
- ¿Cómo sabremos si la predicción es buena?

$$\max P(Felipe\ elija\ bus, Juan\ elija\ metro, Camila\ elija\ bus, \dots)$$

$$= \max P(Bus|(A_F, X_F)) \cdot P\left(Metro\middle|\left(A_J, X_j\right)\right) \cdot P(Bus|(A_C, X_C)) \cdot \dots$$

Maximizar la probabilidad de que lo predicho sea igual a lo observado → Método de Máxima Verosimilitud

- Es posible demostrar que este método reproduce exactamente la partición de mercado observada (muestra)

Propiedades del Modelo Logit Multinomial (MNL)

1) Alternativas con mismo nivel de utilidad

$$V_{iq} = V_{jq} \quad \forall j \Rightarrow P(i|A_q) = \frac{\epsilon^{V_{iq}}}{\sum_{k \in A_q} \epsilon^{V_{kq}}} = \frac{\epsilon^{V_{iq}}}{N \cdot \epsilon^{V_{iq}}} = \frac{1}{N}$$

→ Todas las alternativas son equiprobables

2) Valor límite: probabilidad 0%

$$V_{iq} \ll V_{jq} \quad \forall j \neq i \Rightarrow P(i|A_q) = \frac{\epsilon^{V_{iq}}}{\sum_{k \in A_q} \epsilon^{V_{kq}}} \approx \frac{0}{\sum_{k \in A_q} \epsilon^{V_{kq}}} = 0$$

→ Alternativa nunca será escogida

3) Valor límite: probabilidad 100%

$$V_{iq} \gg V_{jq} \quad \forall j \neq i \Rightarrow P(i|A_q) = \frac{\epsilon^{V_{iq}}}{\sum_{k \in A_q} \epsilon^{V_{kq}}} \approx \frac{\epsilon^{V_{iq}}}{\epsilon^{V_{iq}}} = 1$$

→ Alternativa siempre será escogida

Propiedades del Modelo Logit Multinomial (MNL)

4) Componente aleatoria: distribución con alta dispersión

$$\sigma \gg 1 \quad \mu \to 0 \quad \Rightarrow \quad P(i|A_q) = \frac{\epsilon^{\mu V_{iq}}}{\sum_{k \in A_q} \epsilon^{\mu V_{kq}}} = \frac{1}{\sum_{k \in A_q} \epsilon^{\mu (V_{kq} - V_{iq})}}$$

→ Diferencias en utilidad son irrelevantes. Caso "moneda al aire"

5) Componente aleatoria: distribución con baja dispersión

$$\sigma \to 0 \quad \mu \gg 1 \quad \Rightarrow \quad P(i|A_q) = \frac{\epsilon^{\mu V_{iq}}}{\sum_{k \in A_q} \epsilon^{\mu V_{kq}}} = \frac{1}{\sum_{k \in A_q} \epsilon^{\mu (V_{kq} - V_{iq})}}$$

→ Diferencias en utilidad se tornan muy relevantes. Caso "información perfecta"

Propiedades del Modelo Logit Multinomial (MNL)

6) Constantes modales

En modelos lineales (como son los de utilidad modal), la constante representa la captura de efectos distintos a los que representan los atributos especificados.

Siempre se debe fijar alguna de las constantes en un valor arbitrario, para que el modelo arroje el resto de constantes en forma relativa a la constante fijada

- Ejemplo:

$$V_{Auto} = C_A + \theta_1 X_{1A} + \theta_2 X_{2A} + \theta_3 X_{3A}$$

0

$$V_{Bus} = C_B + \theta_1 X_{1B} + \theta_2 X_{2B} + \theta_3 X_{3B}$$

$$V_{Caminata} = C_C + \theta_1 X_{1C} + \theta_2 X_{2C} + \theta_3 X_{3C}$$

Es usual fijar la constante modal del modo auto en 0. De esta forma, un modelo típicamente bien especificado arrojará constantes modales menores a 0 para el resto de los modos.

Modelo Logit Multinomial (MNL)

- Especificación de la función de utilidad modal (típica)

$$V_i = C_i + \theta_{TV} TV_i + \theta_{TE} TE_i + \theta_{TA} TA_i + \theta_C C_i$$

C_i	$\theta_{TV} TV_i$	$\theta_{TE} TE_i$	$\theta_{TA} TA_i$	$\theta_C C_i$
Constante modal	Tiempo Viaje	Tiempo Espera	Tiempo Acceso	Costo (tarifa)

- Desde microeconomía: Valor Subjetivo del Tiempo (VST)

$$VST = \frac{\theta_T}{\theta_C}$$

Indica cuánto estoy dispuesto a pagar por el ahorro de un minuto de tiempo (de viaje, espera o acceso)

Modelo Logit Multinomial (MNL)

- Elasticidad directa

$$E_{X_{kiq}}^{P_{iq}} = \frac{\partial P_{iq}}{\partial X_{kiq}} \cdot \frac{X_{kiq}}{P_{iq}} = \theta_{ik} X_{kiq} \left(1 - P_{iq}\right)$$

Indica la variación marginal de la probabilidad de un modo frente a variaciones marginales en alguno de los atributos del mismo modo

- Elasticidad cruzada

$$E_{X_{kjq}}^{P_{iq}} = \frac{\partial P_{iq}}{\partial X_{kjq}} \cdot \frac{X_{kjq}}{P_{iq}} = -\theta_{jk} X_{kjq} \left(1 - P_{iq}\right)$$

Indica la variación marginal de la probabilidad de un modo frente a variaciones marginales en alguno de los atributos de otro modo

Modelo Logit Multinomial (MNL)

- La probabilidad de elección modal es totalmente individual
- La partición modal agregada resultante para un modo, entre una población de tamaño Q, queda expresada por:

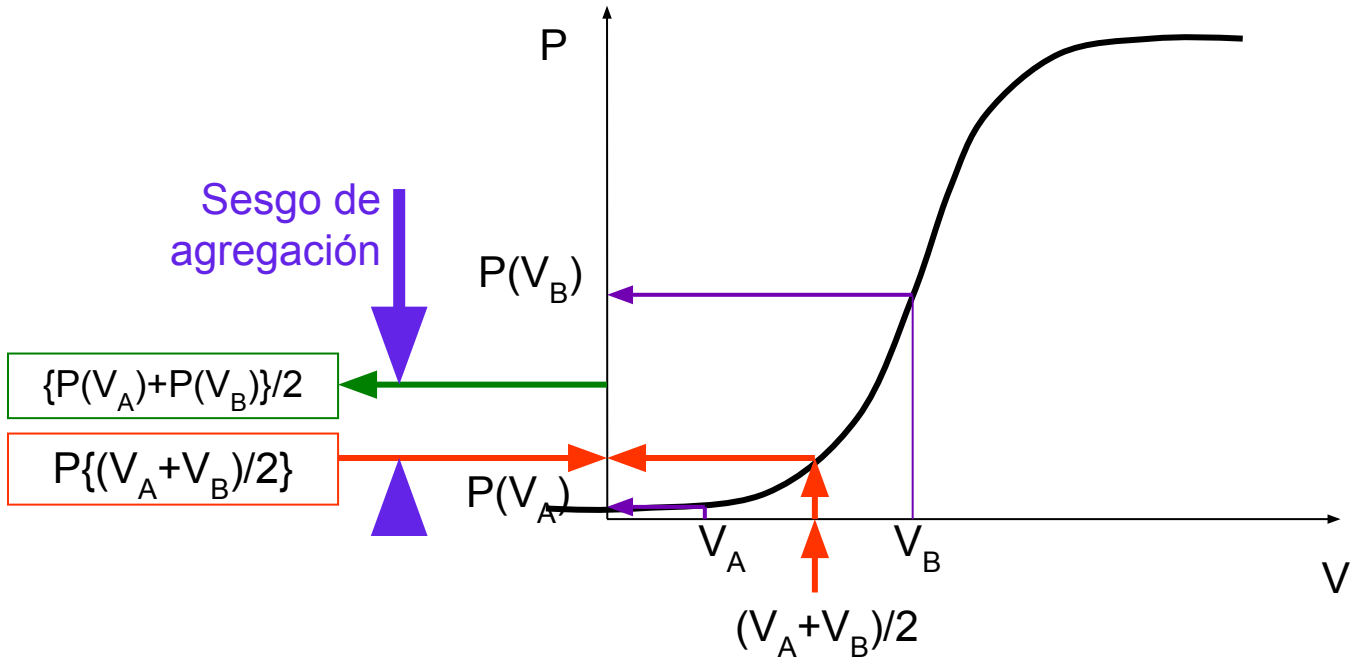
$$P_i = \frac{1}{Q}\sum_{q}^{Q} P_{iq}$$

- Sin embargo, es impracticable estimar probabilidades individuales para cada individuo en poblaciones grandes (como las que se encuentran en las ciudades)
- ¿Cómo realizar entonces una agregación para realizar predicciones en una población?

Estimamos probabilidades agregadas mediante la agregación de los atributos

Modelo Logit Multinomial (MNL)

- Sin embargo, al agregar los atributos se introduce un **sesgo de agregación**



- Aún así, es una buena aproximación al problema
- Existen diferentes enfoques para realizar agregaciones de atributos
  - Enfoque inocente $P_i = P_i(\overline{X_Q})$
  - Enumeración muestral $P_i = \frac{1}{N}\sum_{q}^{N} P_{iq}$
  - Clasificación $P_i = \sum_{c \in Q} \frac{Q_C}{Q} P_i(\overline{X_C})$